

Guía Técnica AG-RACE

Física de Hovercraft y Entrenamiento RL

Senior Physics & RL Engineer

14 de marzo de 2026

1. Introducción

Este documento explica los fundamentos matemáticos del entorno AG-RACE, detallando el modelo de física tipo *hovercraft* y el proceso de aprendizaje por neuroevolución utilizando el algoritmo CMA-ES con una arquitectura de red neuronal profunda.

2. Resumen de Objetivos

El objetivo principal del entrenamiento es crear un piloto que:

- **Maximice la velocidad** sin perder el control (*Drifting* controlado).
- **Mantenga la inercia**: Se penaliza el uso del freno para fomentar el flujo en curvas.
- **Sea extremadamente agresivo**: El contacto con otras naves ahora aplica una fuerza de empuje (*Impulse*) sin pérdida de velocidad.
- **Evite los muros**: El contacto con los límites resulta en eliminación inmediata.

3. Física de Vuelo y Colisiones

3.1. Colisiones entre Naves (Push Physics)

Para fomentar el combate táctico, las colisiones entre agentes se han modificado:

- **Elasticidad**: Al chocar con otra nave, se conserva el 90 % de la velocidad.
- **Impulso**: El vehículo atacante transfiere parte de su inercia al colisionado, ^{em}pujándolo fuera de la trayectoria ideal.

3.2. Modo Obstáculo de Restos (Wreckage)

En la Generación actual, los vehículos destruidos ****no desaparecen**** ni se vuelven intangibles. Permanecen en la pista como obstáculos físicos permanentes, obligando a los supervivientes a realizar maniobras de esquiva dinámica.

3.3. Algoritmo SepCMA (Separable CMA-ES)

Dada la alta dimensionalidad de la red (**13,374 parámetros**), se utiliza la variante *Separable* de CMA-ES. Esto permite optimizar el cerebro de forma lineal en lugar de cuadrática, permitiendo generaciones rápidas incluso en hardware estándar.

4. Optimizaciones de Motor Godot

Para permitir un entrenamiento a velocidad extrema (**x16**), se han implementado:

- **HUD Telemetría:** Visualización en tiempo real de la Generación de IA y estado del servidor Python.
- **Capa de Protección x16:** Bucles defensivos que evitan desbordamientos de memoria cuando los agentes se reinician a alta velocidad.
- **Imitation Teacher Caching:** Optimización de la lógica de sugerencia (imitation reward) mediante el reciclaje de nodos en memoria, reduciendo el micro-stutter en la simulación.

5. Función de Fitness (Actualizado v2)

El sistema utiliza una métrica de aptitud compuesta que premia no solo el avance, sino la consistencia y la superación del experto:

$$F = \text{Media}(R_{ia}) + 2,0 \cdot \text{máx}(0, \text{IA} - \text{Base}) - 1,5 \cdot \text{Std}(R_{ia})$$

Lógica de Entrenamiento Robusto:

- **Evaluación Multi-Semilla:** Cada individuo se prueba en 5 pistas deterministas por generación.
- **Validación Estricta:** El mejor individuo de cada generación se re-evalúa en 12 pistas totalmente nuevas (*Unseen*) para confirmar su capacidad de generalización antes de ser guardado.
- **Reporte PDF en Vivo:** El archivo `resultados.pdf` se genera automáticamente cada 2 generaciones, mostrando el progreso de la IA vs el Baseline.