

Guía Técnica AG-RACE

Física de Hovercraft y Entrenamiento RL

Senior Physics & RL Engineer

14 de marzo de 2026

1. Introducción

Este documento explica los fundamentos matemáticos del entorno AG-RACE, detallando el modelo de física tipo *hovercraft* y el proceso de aprendizaje por neuroevolución utilizando el algoritmo CMA-ES con una arquitectura de red neuronal profunda.

2. Resumen de Objetivos

El objetivo principal del entrenamiento es crear un piloto que:

- **Maximice la velocidad** sin perder el control (*Drifting* controlado).
- **Mantenga la inercia**: Se penaliza el uso del freno para fomentar el flujo en curvas.
- **Sea extremadamente agresivo**: El contacto con otras naves ahora aplica una fuerza de empuje (*Impulse*) sin pérdida de velocidad.
- **Evite los muros**: El contacto con los límites resulta en eliminación inmediata.

3. Física de Vuelo y Colisiones

3.1. Colisiones entre Naves (Push Physics)

Para fomentar el combate táctico, las colisiones entre agentes se han modificado:

- **Elasticidad**: Al chocar con otra nave, se conserva el 90 % de la velocidad.
- **Impulso**: El vehículo atacante transfiere parte de su inercia al colisionado, "empujándolo" fuera de la trayectoria ideal.

3.2. Modo Obstáculo de Restos (Wreckage)

En la Generación actual, los vehículos destruidos ****no desaparecen**** ni se vuelven intangibles. Permanecen en la pista como obstáculos físicos permanentes, obligando a los supervivientes a realizar maniobras de esquiva dinámica.

3.3. Algoritmo SepCMA (Separable CMA-ES)

Dada la alta dimensionalidad de la red (**13,374 parámetros**), se utiliza la variante *Separable* de CMA-ES. Esto permite optimizar el cerebro de forma lineal en lugar de cuadrática, permitiendo generaciones rápidas incluso en hardware estándar.

4. Optimizaciones de Motor Godot

Para permitir un entrenamiento a velocidad extrema (**x16**), se han implementado:

- **HUD Telemetría:** Visualización en tiempo real de la Generación de IA y estado del servidor Python.
- **Capa de Protección x16:** Bucles defensivos que evitan desbordamientos de memoria cuando los agentes se reinician a alta velocidad.
- **Imitation Teacher Caching:** Optimización de la lógica de sugerencia (imitation reward) mediante el reciclaje de nodos en memoria, reduciendo el micro-stutter en la simulación.

5. Función de Fitness (Actualizado)

El sistema ahora aplica un multiplicador agresivo al derrape técnico:

$$F = (\Delta s \times 5000) + (\text{Drift_Check} \times 100) - (\text{Brake_Usage} \times 50)$$

Lógica de Entrenamiento:

- **Evaluación Multi-Semilla:** Cada individuo de la población se prueba en pistas con diferentes configuraciones de curvas para evitar el *overfitting*.
- **Reporte PDF en Vivo:** Generación de informes matemáticos tras cada generación completada.