

Matemática del Entorno AG-RACE y Dinámica del Agente

Proyecto Jackpot Jockeys

11 de marzo de 2026

1. Introducción

Este documento describe el modelo matemático que rige las físicas del vehículo (*Hovercraft*) y las observaciones que el agente de Inteligencia Artificial (IA) realiza dentro del entorno **AG-RACE**. El sistema está diseñado tanto para ser evaluado por heurísticas matemáticas (*Pure Pursuit*) como para entrenar políticas de Aprendizaje por Refuerzo (RL).

2. Dinámica del Vehículo (Modelo Cinemático)

El vehículo se modela en un espacio bidimensional (2D) sujeto a aceleraciones lineales, fricción simulada ("drag") y atenuación de derrapes.

2.1. Estado del Vehículo

El estado dinámico del vehículo se define por su posición global $\mathbf{p} \in \mathbb{R}^2$, su velocidad lineal $\mathbf{v} \in \mathbb{R}^2$ y su rotación (orientación) $\theta \in [-\pi, \pi]$.

2.2. Vectores Direccionales

A partir del ángulo θ , se derivan los vectores dirección frontal (forward) y derecho (right):

$$\hat{\mathbf{f}} = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}, \quad \hat{\mathbf{r}} = \begin{bmatrix} -\sin \theta \\ \cos \theta \end{bmatrix}$$

2.3. Entradas de Control (Acciones)

El agente proporciona tres valores escalares continuos procesados por fotograma interactivo:

- **Aceleración (T):** $T \in [0, 1]$
- **Freno (B):** $B \in [0, 1]$
- **Giro (S):** $S \in [-1, 1]$

2.4. Actualización de Movimiento y Giro

La orientación se actualiza de manera dependiente de la entrada de giro y la velocidad de giro constante ω_{turn} :

$$\theta_{t+\Delta t} = \theta_t + (S \cdot \omega_{turn} \cdot \Delta t)$$

La fuerza de empuje modifica la velocidad a través de la aceleración constante a_{max} y un modificador de fricción ambiental μ_{fric} :

$$\mathbf{v}_{t+\Delta t} = \mathbf{v}_t + \left(\hat{\mathbf{f}} \cdot T \cdot a_{max} \cdot \mu_{fric} \cdot \Delta t \right)$$

Si se aplica freno ($B > 0$), la velocidad se reduce linealmente en contra de su propio vector de movimiento:

$$\mathbf{v}_{t+\Delta t} = \mathbf{v}_t - \left(\frac{\mathbf{v}_t}{|\mathbf{v}_t|} \cdot \min(B \cdot a_{brake} \cdot \mu_{fric} \cdot \Delta t, |\mathbf{v}_t|) \right)$$

2.5. Fricción Diferencial (Drifting)

Para simular el efecto *Hovercraft*, se descompone la velocidad en sus magnitudes frontal (v_f) y lateral (v_l):

$$v_f = \mathbf{v} \cdot \hat{\mathbf{f}} \quad \text{y} \quad v_l = \mathbf{v} \cdot \hat{\mathbf{r}}$$

La velocidad lateral de derrape se atenúa mediante un coeficiente de agarre lateral K_{grip} sujeto a deterioro ambiental μ_{drift} :

$$v_{l,new} = v_l - \text{sgn}(v_l) \cdot \min(|v_l|, K_{grip} \cdot \mu_{drift} \cdot |v_l| \cdot \Delta t)$$

De igual modo, la velocidad frontal sufre atenuación por resistencia al aire (drag) C_d :

$$v_{f,new} = v_f - \text{sgn}(v_f) \cdot \min(|v_f|, C_d \cdot \mu_{fric} \cdot |v_f| \cdot \Delta t)$$

La velocidad final compuesta y re-ensamblada sujeta a los límites físicos V_{max} es:

$$\begin{aligned} \mathbf{v}_{final} &= v_{f,new} \hat{\mathbf{f}} + v_{l,new} \hat{\mathbf{r}} \\ \mathbf{v}_{t+\Delta t} &= \min(|\mathbf{v}_{final}|, V_{max}) \frac{\mathbf{v}_{final}}{|\mathbf{v}_{final}|} \end{aligned}$$

3. Percepción del Agente (Políticas de RL)

El entorno es formulado como un Proceso de Decisión de Markov (MDP) parcialmente observable.

3.1. Proyección en la Pista (Espacio de Frenet)

La curva de la pista central se evalúa como una función paramétrica $C(s) \in \mathbb{R}^2$ donde $s \in [0, L]$ asume L como perímetro total de la pista.

Para cualquier posición global $\mathbf{p}$, existe el escalar $s_{closest}$ que minimiza la distancia euclídea:

$$d_{error}(\mathbf{p}) = \min_s \|\mathbf{p} - C(s)\|$$

Esta métrica d_{error} es devuelta como magnitud absoluta penalizante ("off-track error"). Adviértase que, si el vehículo sobrepasa el ancho asimilado asintóticamente de la pista ($W_{track}/2$), tal valor escala significativamente para penalizar severamente a la política RL.

3.2. Error de Orientación (Heading Error)

El error es obtenido a partir de una pre-sintonía de distancia proyectada $D_{lookahead}$ asumiendo:

$$Target = C((s_{closest} \cdot L + D_{lookahead}) \pmod{L})$$

El vector unitario óptimo de avance es $\hat{\mathbf{u}} = \frac{Target - \mathbf{p}}{|Target - \mathbf{p}|}$. El error direccional alimentado a las observaciones se computa contra $\hat{\mathbf{f}}$:

$$e_\theta = \arccos(\hat{\mathbf{u}} \cdot \hat{\mathbf{f}}) \quad \text{Normalizado bajo } \left[\frac{e_\theta}{\pi} \right]$$

3.3. Vector Estocástico

Las observaciones recopiladas construyen un vector matricial $O_t \in \mathbb{R}^{20}$ combinando magnitudes intrínsecas del vehículo (velocidades relativas, variables de atascamiento), discrepancias espaciales (errores e_θ, d_{error}) y perturbaciones del World Event Manager derivadas como ruido inyectado, determinando la dinámica de transición de las políticas de aprendizaje.