

Matemática del Entorno AG-RACE y Dinámica del Agente

Proyecto Jackpot Jockeys

14 de marzo de 2026

1. Introducción

Este documento establece la formalización matemática rigurosa del entorno **AG-RACE**. Este entorno está diseñado para entrenar agentes autónomos (*Hovercrafts*) bajo el paradigma de Aprendizaje por Refuerzo Multi-Agente (MARL) o Neuroevolución. Describimos la generación geométrica de la pista, la cinemática del vehículo, la configuración estricta del vector de observaciones y el objetivo de optimización final.

2. Formulación del Entorno como un POMDP

AG-RACE se modela formalmente como un Proceso de Decisión de Markov Parcialmente Observable (POMDP) definido por la tupla $\langle S, A, T, R, \Omega, O, \gamma \rangle$, acondicionado por una semilla inicial de caos ω :

- S : Espacio de estados globales (Posiciones, velocidades, deformación de pista, eventos activos).
- A : Espacio de acciones continuas del vehículo $\mathbf{a} \in [-1, 1]^3$.
- $T(s_{t+1}|s_t, a_t; \omega)$: Función de transición **determinista** controlada por la semilla ω .
- $R(s_t, a_t)$: Recompensa escalar basada en progreso topológico y penalizaciones.
- O : Espacio de observación compuesto por sensores locales.
- $\Omega(o_t|s_t)$ Función determinista que extrae la vista parcial del agente a partir del estado real.

3. Generación Procedural de Pistas (Curvas Hérmite)

Para inducir políticas que generalicen sobre geometrías nunca vistas, la pista se genera proceduralmente en N *waypoints* P_i . La trayectoria suave y continua $C(s)$ se modela utilizando **Splines de Hermite Cúbicos**. Dado un parámetro de interpolación $u \in [0, 1]$ entre dos puntos P_0 y P_1 , la curva evalúa a:

$$C(u) = (2u^3 - 3u^2 + 1)P_0 + (u^3 - 2u^2 + u)M_0 + (-2u^3 + 3u^2)P_1 + (u^3 - u^2)M_1$$

Donde M_0 y M_1 son las tangentes direccionales:

$$M_i = \nabla P_i \approx \frac{1}{2}(P_{i+1} - P_{i-1})$$

3.1. Curvatura Estimada y Vector Ideal

El agente necesita percibir la topología verdadera. Se calcula un vector ideal normalizado de *Heading* diferenciando la spline respecto al progreso s :

$$\hat{\mathbf{h}}_{ideal}(s) = \frac{\frac{d}{ds}C(s)}{\left\| \frac{d}{ds}C(s) \right\|}$$

La tasa de cambio direccional entre dos vectores de rotación $\Delta\theta$ separados por una distancia pequeña Δs otorga la **Curvatura Local** observada:

$$\kappa(s) = \frac{\Delta\theta}{\Delta s} \quad (\text{rad/m})$$

4. Dinámica de Actuación y Física (Hovercraft)

La nave no opera como un coche tradicional; obedece al movimiento 2D resbaladizo.

4.1. Aplicación del Vector de Control

El vector de acción $\mathbf{a}_t = [\mathbf{u}_{throttle}, \mathbf{u}_{brake}, \mathbf{u}_{steer}]$ influye directamente en la posición $\mathbf{p}_t = \begin{bmatrix} x_t \\ y_t \end{bmatrix}$. Las variables están constreñidas al rango normalizado: $T, B \in [0, 1]$ y $S \in [-1, 1]$.

$$\theta_{t+\Delta t} = \theta_t + (\mathbf{u}_{steer} \cdot V_{turn_ratio} \cdot \Delta t)$$

La aceleración lineal ocurre sobre el eje *Forward* rotado localmente a $\theta_{t+\Delta t}$:

$$\mathbf{v}_{t+\Delta t} = \mathbf{v}_t + \left(\begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix} \cdot \mathbf{u}_{throttle} \cdot A_{max} \cdot \Delta t \right)$$

4.2. Atenuación Transversal (Drift) Acoplado al Clima

Una fracción de la velocidad transversal v_l respecto a la inercia debe atenuarse para evitar que el hovercraft gire infinitamente. Esto se gobierna mediante la Fricción Lateral Constante $\mu_{L.base}$:

$$v_{l,new} = v_l - \text{sgn}(v_l) \cdot \text{mín}(|v_l|, \mu_{L.base} \cdot (1 - \lambda_{clima}) \cdot \Delta t)$$

Donde λ_{clima} es el decaimiento inducido por Eventos de Mundo como pistas congeladas o aceite.

5. Espacios de IA: Observación y Recompensa

5.1. Estructura Base del Vector de Observaciones (OBS_SCHEMA_V2 = 59 Dims)

El agente capta un vector normalizado continuo $o_t \in \mathcal{R}^{59}$ de alta fidelidad, estructurado jerárquicamente:

1. **Estado Propio (6D):** Velocidad (X, Y, Mag), Progreso Topológico, Desvío Lateral y Contador de Atascamiento (*Stuck*).
2. **Relación de Pista (4D):** Ángulo ideal vs real (*Heading Error*), Curvatura local y ancho de pista.
3. **Sensores LIDAR (20D):** Rayos de distancia a los límites de la pista en un radio de 360 grados.

4. **Percepción de Rivales (18D):** Datos relativos de los 3 rivales más cercanos (Distancia, Ángulo, Velocidad Relativa).
5. **Eventos y Peligros (7D):** Estado de ráfagas de viento y zonas de baja fricción detectadas.
6. **Parámetros Globales (4D):** Gravedad local, fricción base y configuración de empuje.

5.2. Capa de Seguridad (Rule-Based Fallback)

Para acelerar la convergencia en el RL Inicial (Evitar quedarse girando de frente al muro), la inferencia neuronal se reescribe determinísticamente bajo las siguientes condiciones ineludibles de seguridad temporal $F(s_t, \mathbf{a}_t)$:

$$\mathbf{a}_t^* = \begin{cases} [-1, 1, -\text{sgn}(\mathbf{u}_{steer})], & \text{si } stuck_timer > 1,5s \text{ (Fuerza Reversa)} \\ [0, 2, 0, 8, \mathbf{K}_p \cdot \text{Dir}], & \text{si } err_{lateral} > 50m \text{ (Fuerza Retorno Auto-Steering)} \\ \mathbf{a}_t, & \text{en cualquier otro caso (Output Neuronal Libre)} \end{cases}$$

AG-RACE implementa recompensas densas de avance y una métrica de aptitud (*Fitness*) comparativa. El entrenamiento se realiza mediante **Separable CMA-ES (SepCMA)**, optimizando los 13,374 parámetros de la red neuronal.

Definimos la función de Aptitud Global F para una red con pesos Φ :

$$F(\Phi) = \bar{R}_{agent} + w_g \cdot \max(0, \bar{R}_{agent} - \bar{R}_{base}) - w_v \cdot \sigma_R$$

Donde:

- $\bar{R}_{agent}$: Recompensa media del agente sobre $K = 5$ semillas de evaluación.
- $\bar{R}_{base}$: Rendimiento medio del **Baseline Agent** (Profesor) en las mismas pistas.
- w_g : Peso del *Gap* respecto al baseline (Fomenta superar al experto).
- w_v : Penalización por varianza σ_R (Fomenta la estabilidad y generalización).

El límite de simulación se establece en 300 pasos por episodio a 60 FPS, incentivando políticas de alta velocidad y eficiencia.